

Learning Analytics

Spezielle Forschungsmethoden in der Bildungstechnologie

Dirk Ifenthaler und Hendrik Drachsler

Inhalt

1	Einleitung	516
2	Learning Analytics	516
3	Learning Analytics im pädagogischen Kontext	523
4	Anwendungsszenarien	526
5	Fazit	529
	Literatur	532

Zusammenfassung

Der Forschungsbereich um Learning Analytics hat sich in den vergangenen fünf Jahren rasant entwickelt. Learning Analytics verwenden statische Daten von Lernenden und dynamische in Lernumgebungen gesammelte Daten über Aktivitäten (und den Kontext) des Lernenden, um diese in nahezu Echtzeit zu analysieren und zu visualisieren, mit dem Ziel der Modellierung und Optimierung von Lehr-Lernprozessen und Lernumgebungen. Learning Analytics kann sowohl auf Kursebene als auch auf curricularer Ebene sowie institutionsweit bzw. -übergreifend implementiert werden. Trotz der großen Aufmerksamkeit für das Thema Learning Analytics in der Wissenschaft steckt die praktische Anwendung von Learning Analytics noch in den Anfängen. Dennoch müssen Bildungsinstitutionen bereits jetzt Kapazitäten entwickeln, um der aktuellen Entwicklung folgen zu können. Es bleibt zu erwarten, dass neben datenschutzrechtlichen Regelungen in

D. Ifenthaler (✉)

Learning, Design and Technology, Universität Mannheim, Mannheim, Deutschland

E-Mail: dirk@ifenthaler.info; ifenthaler@bwl.uni-mannheim.de; ifenthaler@uni-mannheim.de

H. Drachsler

Deutsches Institut für Internationale Pädagogische Forschung, Goethe Universität Frankfurt am Main, Frankfurt, Deutschland

E-Mail: drachsler@dipf.de

der Verwendung von Learning Analytics auch technische Standards zum Austausch von Daten aus dem Bildungskontext entwickelt werden.

Schlüsselwörter

Learning Analytics · Educational Data Mining · Datenanalyse · Big Data · Academic Analytics

1 Einleitung

Im wirtschaftlichen Kontext werden nutzergenerierte Daten bereits vielfältig für datenevidente Entscheidungen genutzt. Auch im Bildungsbereich insbesondere durch die Bereitstellung und Nutzung von digitalen Lernangeboten nimmt die Datenfülle kontinuierlich zu. Aktuell werden die Möglichkeiten von Daten in Bildungsinstitutionen jedoch nur gering ausgeschöpft (Ifenthaler und Schumacher 2016a; Drachsler und Greller 2016; Drachsler et al. 2014).

Konzepte wie Educational Data Mining, Academic Analytics und Learning Analytics finden derzeit vor allem in den USA, den Niederlanden, Großbritannien und Australien starke Beachtung. Educational Data Mining bereitet aus der Menge aller verfügbaren Daten relevante Informationen für den Bildungsbereich auf (Berland et al. 2014). Academic Analytics beziehen sich vornehmlich auf die Leistungsanalyse von Bildungsinstitutionen, indem institutionelle, lernendenbezogene und akademische Daten verwendet werden und für Vergleiche genutzt werden (Long und Siemens 2011). Bei Learning Analytics stehen Lernende, Lernprozesse und in Echtzeit verfügbare Rückmeldungen im Vordergrund (Greller und Drachsler 2012; Ifenthaler 2015).

Im Folgenden soll ein Überblick über Learning Analytics, insbesondere im Hochschulkontext, gegeben sowie zukünftige Entwicklungsmöglichkeiten aufgezeigt werden. Zunächst werden vor dem Hintergrund von Rahmenkonzepten die grundlegenden Annahmen von Learning Analytics erarbeitet. Anschließend werden Learning Analytics im pädagogischen Kontext eingeordnet. Des Weiteren werden fünf Anwendungsszenarien von Learning Analytics vorgestellt. Schließlich wird ein Fazit gezogen und es werden zukünftige Entwicklungen aufgezeigt.

2 Learning Analytics

2.1 Definition

Der Forschungsbereich um Learning Analytics hat sich in den vergangenen fünf Jahren rasant entwickelt. Diese Entwicklung ist vorallem der engen Verbindung von Learning Analytics und sogenannten *Massive Open Online Courses (MOOCs)* zuzuordnen (Drachsler und Kalz 2016), sowie der schnell voranschreitenden Digitalisierung der Gesellschaft im Allgemeinen (Ifenthaler et al. 2015). Die Frage nach

einer einheitlichen Definition, was Learning Analytics sind, konnte jedoch noch nicht zufriedenstellend geklärt werden. Eine weit verbreitete Definition wurde im Rahmen der ersten internationalen Konferenz um Learning Analytics und Knowledge (LAK 2011) postuliert: *Learning Analytics sind das Messen, Sammeln, Analysieren und Auswerten von Daten über Lernende und ihren Kontext mit dem Ziel, das Lernen und die Lernumgebung zu verstehen und zu optimieren.* Um die Dynamik der generierten Daten aus dem Bildungsbereich sowie die Vorteile der Echtzeitanalyse, -visualisierung und -rückmeldung von Learning Analytics einzubeziehen schlagen Ifenthaler und Widanapathirana (2014) folgende Definition vor: *Learning Analytics verwenden statisch und dynamisch generierte Daten von Lernenden und Lernumgebungen, um diese in Echtzeit zu analysieren und zu visualisieren, mit dem Ziel der Modellierung und Optimierung von Lehr-Lernprozessen und Lernumgebungen.*

Learning Analytics kann auf verschiedenen Ebenen verwendet werden. Sowohl auf Kursebene als auch auf curricularer Ebene sowie institutionsweit bzw. -übergreifend (Ifenthaler 2015). Greller und Drachsler (2012) bezeichnen die unterschiedlichen Ebenen als Micro-, Meso- und Macro-Ebenen (siehe Abb. 1). Die Ebenen unterscheiden sich hinsichtlich verwendeter Daten, Analysefunktionen, Nutzerkreis und Einsichten. Die Micro-Ebene befasst sich hauptsächlich mit den Bedürfnissen von Lehrenden und Lernenden und zielt auf einzelne Kurse ab. Die Meso-Ebene zielt auf eine Sammlung von Kursen oder ein Curriculum ab und bietet vor allem Informationen für Entscheidungsträger. Die Macro-Ebene hält Informationen für eine ganze Organisation oder eine wissenschaftliche Disziplin bereit.

2.2 Sechs Dimensionen von Learning Analytics

Während der Begriff Learning Analytics den Eindruck vermittelt, dass er vor allem auf die Berechnung, Aggregation und Analyse von gesammelten Daten ausgerichtet ist, ist das Gegenteil der Fall. Learning Analytics erfordern einen ganzheitlichen Ansatz für bestehende Prozesse im Bildungsbereich, sowie für das Lernen und Lehren selbst. Greller und Drachsler (2012) haben dies in einem Learning Analytics Framework beschrieben. Das Learning Analytics Framework zeigt, dass die Vielfalt der Themen für Learning Analytics sehr unterschiedlich sind und einander beeinflussen. Greller und Drachsler (2012) identifizierten sechs kritische Dimensionen für Learning Analytics (siehe Abb. 2).

2.2.1 Stakeholder: Zielgruppen von Learning Analytics

Die Stakeholder-Dimension umfasst vor allem Lernende und Lehrende, jedoch sind hier auch alle anderen Beteiligten gemeint wie zum Beispiel Eltern, Bildungsmanagement oder politische Entscheidungsträger. Greller und Drachsler (2012) klassifizieren die Learning Analytics-Zielgruppen in sogenannten Data-Subjects und Data-Clients. Data-Subjects sind die Personen, deren Daten informationstechnisch gesammelt und ausgewertet werden, während die Data-Clients diese Daten verarbeiten und Rückschlüsse ziehen. Auf der Micro-Ebene, also dem klassischen Klassen- oder

Abb. 1 Unterschiedliche Ebenen von Learning Analytics (Greller und Drachsler 2012)

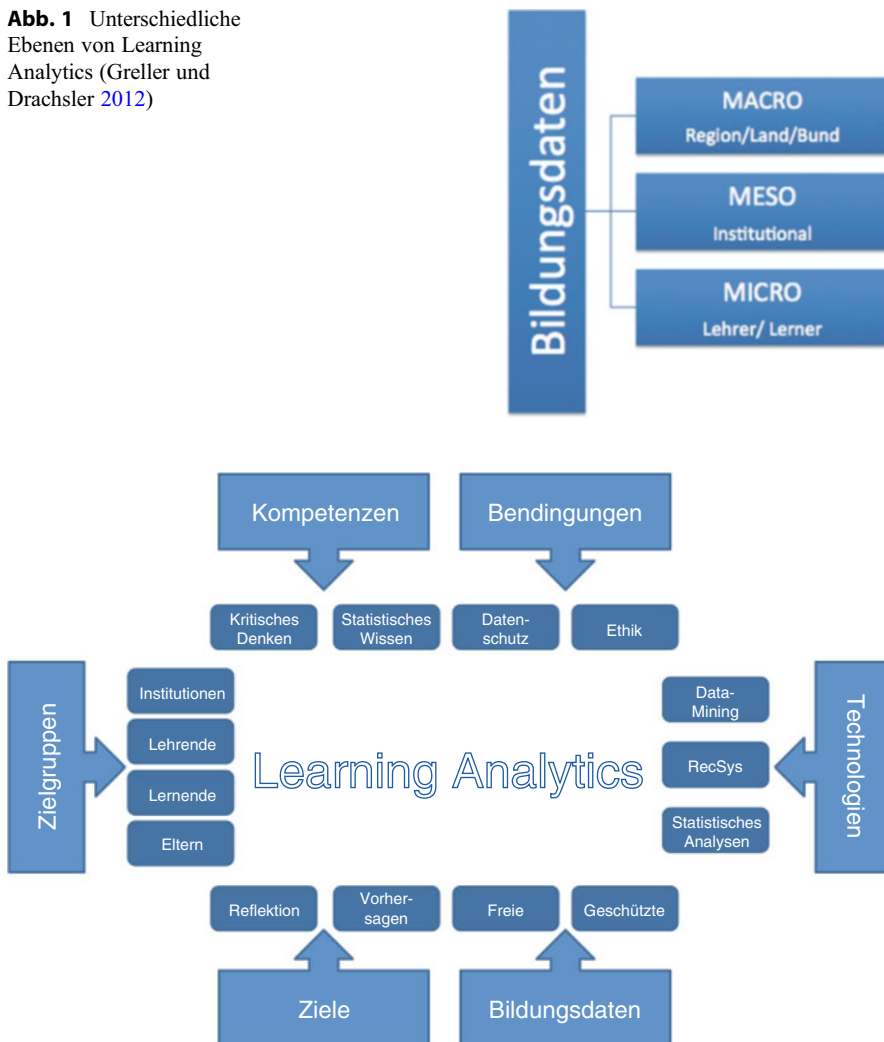


Abb. 2 Das Learning Analytics Framework aus dem Englischen übersetzt von Greller und Drachsler 2012

Kursraum, werden Lernende als Data-Subjects und Lehrende als Data-Clients bezeichnet. Allerdings können unter bestimmten Bedingungen sowie auf höheren Learning Analytics-Ebenen (Meso- oder Macro-Ebene) auch Lehrende oder eine ganze Institution zu Data-Subjects werden. Die Begriffe Data-Subjects und Data-Clients sind daher nicht direkt als synonyme für Lernende und Lehrende zu nutzen. Auf bestimmten Ebenen oder bei nicht traditionellen Lehrkonzepten können auch Lehrende zu Data-Subjects werden (z. B. Teaching Analytics) oder Lernende zu Data-Clients (z. B. Peer-Feedback).

2.2.2 Objectives: Ziele von Learning Analytics

Der innovative Charakter von Learning Analytics liegt vor allem in der Möglichkeit bisher unbekannte Zusammenhänge durch Visualisierungen oder Data Mining-Techniken aus bestehenden Bildungsdaten darzustellen und verschiedenen Zielgruppen zur Verfügung zu stellen. Diese neuartigen Informationen versprechen sowohl individuelle Lern- oder Lehrprozesse als auch Gruppenprozesse mit neuen Erkenntnissen zu unterstützen, sowie Adaptionen von Lernmaßnahmen an individuelle Bedürfnisse durchzuführen. Die Hauptziele von Learning Analytics werden in Abschn. 3.2 näher beleuchtet.

2.2.3 Data: Frei zugängliche Bildungsdaten und geschützte Daten

Learning Analytics verwenden Datensätze aus verschiedenen elektronischen Systemen. Die meisten in von Bildungsinstitutionen betriebenen Systemen gesammelten Daten sind datenrechtlich geschützt (protected). Neben diesen geschützten Datenbeständen gibt es auch eine zunehmende Anzahl von öffentlichen Daten (sogenannte open data oder linked data (d'Aquin et al. 2014)), die mit internen Datensätzen kombiniert werden können, wie zum Beispiel Postleitzahlen mit online verfügbaren Kartenmaterial oder offen zugänglichen Daten von Seiten der Regierungen oder internationalen Organisationen wie zum Beispiel OECD oder Non-Government-Organisationen. Neben den geschützten und offenen Datenbeständen entstehen im Learning Analytics-Bereich auch erste Metadaten-Standards, wobei momentan der Daten-Standard xAPI sowie der Daten Standard Caliper vom IMS Consortium miteinander konkurrieren (Berg et al. 2016). Weiterführende Informationen zum Thema Metadaten in Learning Analytics können auf der Webseite des LACE-Projektes gefunden werden (www.LACEproject.eu).

2.2.4 Instruments: Technologien, Algorithmen und Theorien für Learning Analytics

Verschiedene Technologien und Algorithmen können in der Entwicklung und Anwendungen von Learning Analytics verwendet werden. Learning Analytics nutzt so genannte Information Retrieval-Technologien wie vom Machine Learning Algorithmen (Di Mitri et al. 2017), Recommender Systeme (Drachler et al. 2015; Fazeli et al. 2014) oder klassische statistische Analyseverfahren in Kombination mit verschiedenen Visualisierungstechniken. Häufig werden die mit den verschiedenen technischen Verfahren analysierten Daten in sogenannten Dashboards an verschiedene Zielgruppen mit unterschiedlichen Informationen ausgegeben (Scheffel et al. 2016; Jivet et al. 2017).

2.2.5 External Constraints: Restriktionen und Bedingungen von Learning Analytics

Die groß angelegte Produktion, Sammlung, Aggregation und Verarbeitung von Informationen aus Bildungssystemen haben zu ethischen und datenschutzrechtlichen Bedenken hinsichtlich der potenziellen Schädigung von Individuen und Gesellschaft geführt. Dementsprechend hat die Open University UK eine Richtlinie zum

Umgang mit Learning Analytics veröffentlicht.¹ Die University of Edinburgh ist diesem Beispiel gefolgt und hat ebenfalls verschiedene ethische und datenschutzrechtliche Richtlinien und Maßnahmen für die Nutzung von Learning Analytics veröffentlicht.² Drachsler und Greller haben auf der Learning Analytics-Konferenz 2016 in Edinburgh die DELICATE Checkliste veröffentlicht, die die komplexen rechtlichen Rahmenbedingungen in einer handlichen Checkliste zusammenfasst. Das Ziel der DELICATE Checkliste (siehe Abb. 3) ist es, ein einfaches Instrument für jede Bildungseinrichtung zu sein, dass das Bewusstsein der Mitarbeiter in der Organisation rund um Ethik und Datenschutz steigert und damit das Thema demystifiziert und aus der komplexen Welt von juristischen Texten extrahiert und in der Praxis besprechbar macht. Neben der Checkliste sollte der unterstützende Leitartikel gelesen werden, um in die wichtigsten Gedankengänge eingeführt zu werden (Drachsler und Greller 2016).

Ifenthaler und Tracey (2016) veröffentlichten ein Special Issue in Educational Technology, Research and Development zu Fragen um Ethik, Datenschutz und Privatheit von Daten im Rahmen von Learning Analytics-Anwendungen. Die Beiträge zeigen, dass der Datenschutz und Persönlichkeitsrechte einen zentralen Problembereich in der Anwendung von Learning Analytics darstellen. Bildungsinstitutionen müssen Persönlichkeitsrechte berücksichtigen, wenn Daten gesammelt, gespeichert und ausgewertet werden. Hierbei sind Fragen zu klären, die sich auf die pädagogische Relevanz der erhobenen Daten beziehen (Ifenthaler und Schumacher 2016b): (1) Was soll erfasst werden und warum? (2) Wer trifft die Entscheidung? (3) Sind Lernende überhaupt in der Lage ihre eigenen Daten zu interpretieren? (4) Inwieweit sollten die Daten Dritten zugänglich gemacht werden? Darüber hinaus spielen auch ethische Fragen eine Rolle: (5) Welche Informationen liefern für den Lernenden einen pädagogischen Mehrwert? (6) Ist es beispielsweise sinnvoll, einem Lernenden mitzuteilen, dass aufgrund seiner bisherigen Leistungen nur eine geringe Wahrscheinlichkeit besteht, dass er die Klassenstufe besteht?

2.2.6 Internal Limitations: Benötigte Kompetenzen für die Akzeptanz von Learning Analytics

Um Learning Analytics zu einem effektiven Instrument für das Bildungssystem zu machen, ist es wichtig zu erkennen, dass Learning Analytics nicht mit der Darstellung der Ergebnisse algorithmischer Berechnungen in attraktiven Visualisierungen endet. Die Ergebnisse bedürfen einer Interpretation von Seiten der Stakeholder und dies erfordert wiederum gewisse Kompetenzen wie interpretative und kritische Evaluierungskompetenzen. Diese Fähigkeiten sind bislang kein Standard für die am Bildungsprozess beteiligten Personen (Greller und Drachsler 2012; Gibson und Ifenthaler 2017). Darüber hinaus gibt es die Fragestellung bezüglich des Effektes von Learning Analytics im Hinblick auf den eigentlichen Lernerfolg. Scheffel und

¹<http://www.open.ac.uk/students/charter/essential-documents/ethical-use-student-data-learning-analytics-policy>.

²<http://www.ed.ac.uk/information-services/learning-technology/learning-analytics>.

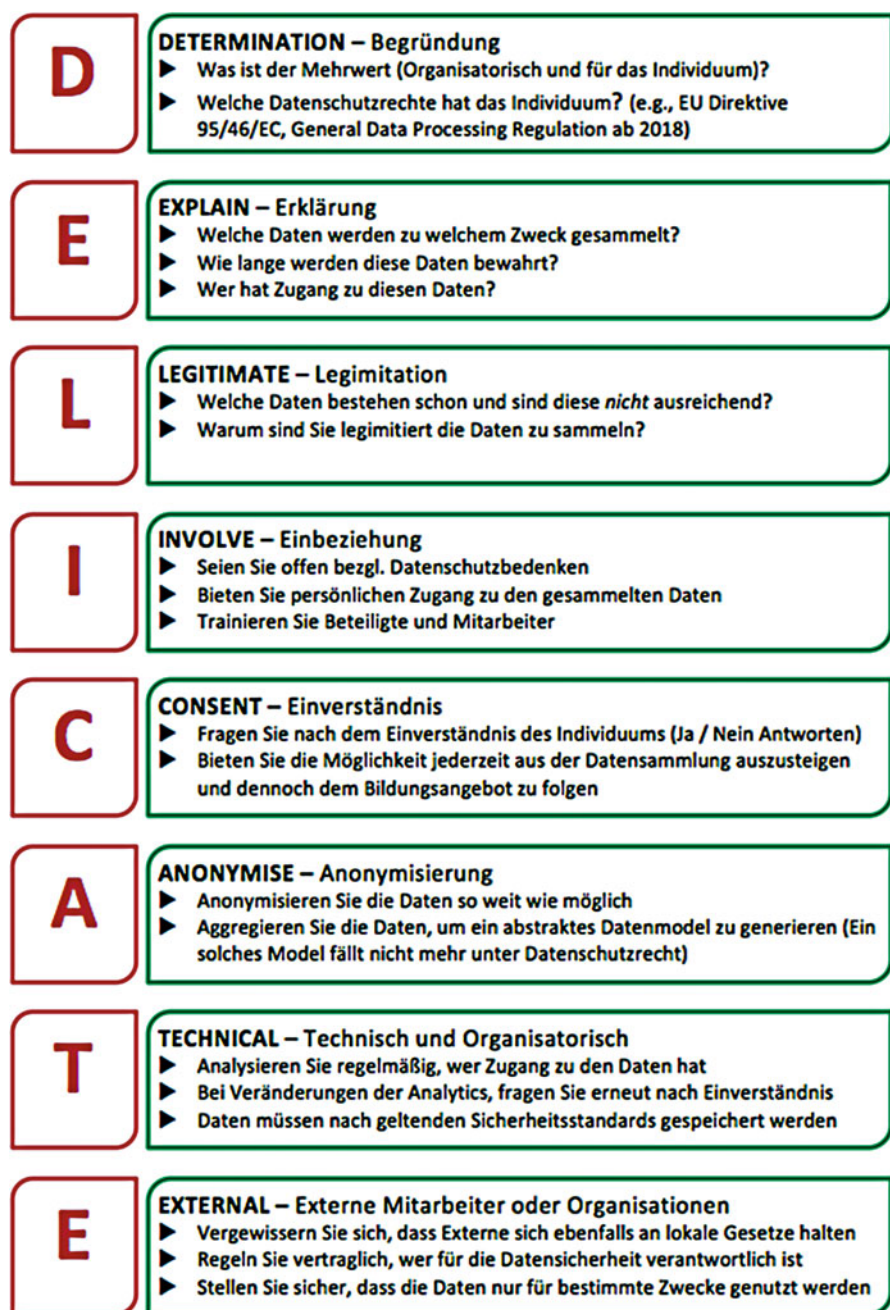


Abb. 3 Die DELICATE-Checkliste aus dem Englischen von Drachsler und Greller 2016

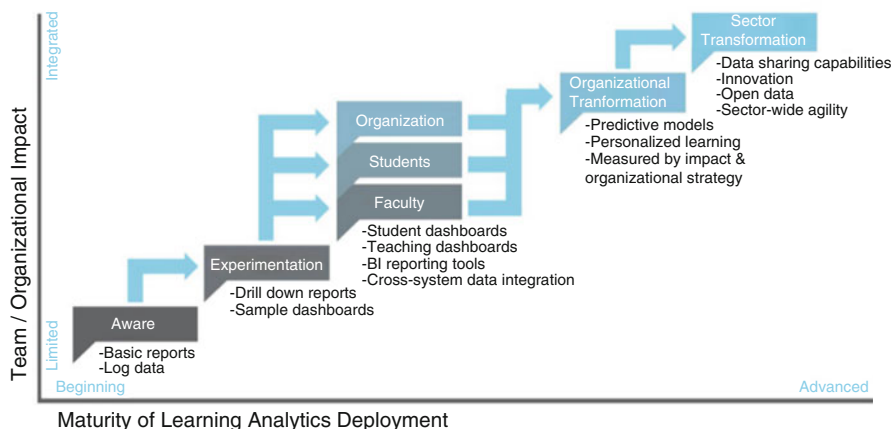


Abb. 4 The Learning Analytics Sophistication Model (Siemens et al. 2014)

Kollegen (2014) haben hierfür eine erste Studie zu Qualitätskriterien für Learning Analytics durchgeführt und ein Evaluationskonzept für Learning Analytics etabliert, das auf der Webseite des Europäischen LACE-Projektes gefunden werden kann (<http://www.laceproject.eu/evaluation-framework-for-la/>).

2.3 Verwendung von Learning Analytics

Trotz der großen Aufmerksamkeit für das Thema Learning Analytics in der Wissenschaft und verschiedenen (Startup-)Unternehmen, steckt die praktische Anwendung von Learning Analytics noch in den Kinderschuhen. In Anbetracht des von der Society of Learning Analytics Research (SoLAR) entwickelten fünfstufigen Sophistication-Modells (siehe Abb. 4) bleibt noch viel zu tun, um den Bildungsbereich in Europa und vor allem in Deutschland in einen mit Daten unterstützten Gesellschaftsbereich zu transformieren. Anhand des Sophistication-Modells sind die meisten Bildungseinrichtungen in Europa nach wie vor auf der Stufe 1 (Aware) und nur sehr wenige fortgeschrittene Organisationen auf Ebene 2 (Experimentation) oder 3 (Institution wide use).

Wir sind relativ sicher, dass im gegenwärtigen Stadium keine Organisation auf der Welt behaupten kann, alle fünf Reifegrade erreicht zu haben. Der Grund dafür ist, dass es trotz der großen Begeisterung umfassende Fragen auf Seiten der Forschung und Organisationsentwicklung gibt, welche die Akzeptanz von Learning Analytics und deren Weiterentwicklung verlangsamen. In einigen prominenten Fällen wurde die Implementation von Learning Analytics sogar rückgängig gemacht, nachdem die Regierung und Bürgerrechtsgruppen über den Schutz der Privatheit der verwendeten Daten sowie die ihrer Kinder besorgt waren (New York Times 2014). Das bekannteste Beispiel ist hier sicherlich das 100 Million \$ joint venture der Bill Gates Foundation und der amerikanischen Mitgliedstaaten genannt inBloom. InBloom

war ein länderübergreifendes Datenportal für Schulen in den USA, dass personalisierte Inhalte anbieten konnte. Jedoch musste inBloom sehr bald nach seiner Errichtung aufgrund massiver Proteste von Bürgerrechtsorganisationen und besorgten Eltern geschlossen werden.³

Drachsler, Stoyanov und Specht konnten in einer Studie aus dem Jahre 2014 zeigen, dass die Bereitschaft zu Implementierung und Nutzung von Learning Analytics in den Niederlanden schon zu dieser Zeit als sehr hoch eingeschätzt wurde. In der Tat sind in den darauffolgenden Jahren viele Learning Analytics-Initiativen sowohl von Seiten der Universitäten als auch von Seiten der niederländischen Forschungsgemeinschaft SURF initiiert worden. Die Akzeptanz von Learning Analytics im internationalen Durchschnitt hingegen ist laut einer Studie von Ifenthaler (2017) noch recht mäßig gegeben, nur wenige Hochschulen verfügen über spezialisiertes Personal für Learning Analytics. So berichten zum Beispiel nur 25 % der befragten Institutionen, dass Personen mit Spezialisierung in Learning Analytics tätig sind. Auch die notwendigen Technologien werden an den Hochschulen unzureichend vorgehalten. Auf der anderen Seite sind sich die Vertreter der Institutionen jedoch einig, dass Learning Analytics viele Vorteile auf allen Ebenen der Hochschulen bieten können. Der größte Nutzen wird dabei für die Lernenden und Lehrenden gesehen (Ifenthaler 2017).

3 Learning Analytics im pädagogischen Kontext

Besonders für den Einsatz im Hochschulbereich eignen sich Learning Analytics, indem Lernende ihr Lernverhalten reflektieren und mit dem anderer vergleichen können. Ebenso wird den Lehrenden die Möglichkeit gegeben, den Lernprozess der Lernenden zu begleiten und gegebenenfalls individuelle Unterstützung anzubieten sowie die eigene Lehre zu reflektieren und an die Lernenden anzupassen. Die Lernenden erhalten Feedback, mit Hilfestellungen zu weiteren Schritten, die ihren Lernprozess unterstützen können. Die Lehrenden werden über die Lernleistung der Studierenden informiert, so dass sie beispielsweise persönlichen Kontakt zu den Lernenden aufnehmen können, die Schwierigkeiten haben (Pistilli und Arnold 2010).

3.1 Lehr-Lerntheorien für den Einsatz von Learning Analytics

Aus Sicht der Lehr-Lern-Forschung sind zwei entscheidende Prozesse für die sinnvolle Nutzung von Learning Analytics sowohl auf Seiten der Lernenden als auch auf Seiten der Lehrenden relevant. (1) Der Prozess der „Wahrnehmung“ (awareness), und (2) der Prozess der „Reflektion“ (reflection). Beide Prozesse müssen beim Umgang mit Learning Analytics Dashboards sowie Vorhersagen (predictions) berücksichtigt werden.

³http://bits.blogs.nytimes.com/2014/04/21/inbloom-student-data-repository-to-close/?_r=1.

Die Wahrnehmung spielt nach Endsley (1995) eine zentrale Rolle für die spätere Reflektion der Informationen. Nach Endsley (1995) ist die Wahrnehmung der eigenen Situation ein dreistufiger Prozess (1. Wahrnehmung, 2. Verständnis, 3. Projektion) und eine Grundlage für die Entscheidungsfindung und effektive Durchführung des weiteren Lernprozesses. Nach der Wahrnehmung des aktuellen Lernstatus erfolgt das Verständnis der aktuellen Lernsituation und der daraus führenden Projektion eines zukünftigen gewollten Wissensstandes oder eines zu erwerbenden Kompetenzniveaus. Die kritische Reflektion kann dann Einsichten ermöglichen über ein unbeabsichtigtes Verhalten und zu einer Veränderung im Lern- oder Lehrverhalten führen. Wahrnehmung und Reflektion sind also zwei sich bedingende und zentrale Bestandteile für einen mit Learning Analytics unterstützten Lernprozess.

Neben der Wahrnehmung und der Reflektion ist für den effektiven Umgang mit Feedback im allgemeinen und Learning Analytics im speziellen die Fähigkeit des selbstgesteuerten Lernens von großer Bedeutung. Zimmerman (1995) beschreibt selbstgesteuertes Lernen als eine Kernkompetenz für den Umgang mit Feedback-Systemen, weil diese den Lernenden befähigt selbstverantwortlich mit den Informationen eines Feedback-Systems (z. B. Learning Analytics Dashboard) umzugehen und das bisherige Verhalten bei Bedarf anzupassen, aber auch in der Lage zu sein, die vom Learning Analytics Dashboard präsentierten Informationen in Frage zu stellen. Learning Analytics sind folglich stark lernendenzentriert und fördern über Reflektionsanreize (Prompts) den Lernprozess (Ifenthaler 2012), wobei durch zeitnahes Feedback und das Wissen über das eigene Lernen der Lernerfolg verbessert werden kann.

3.2 Nutzen von Learning Analytics

Learning Analytics bieten durch die Analyse großer Datenmengen eine weitaus differenziertere Informationsbasis als das in klassischen Lehr-Lern-Situationen durch eine einzelne Lehrperson möglich wäre. Nach Verbert et al. (2012) sollten Learning Analytics mit verschiedenen Methoden Daten multipler Quellen analysieren und folgende Ziele vereinen:

- Relevante nächste Lernschritte und Lernmaterialien empfehlen
- Reflektion und Bewusstsein über den Lernprozess fördern
- Soziales Lernen fördern
- Unerwünschtes Lernverhalten und -schwierigkeiten aufspüren
- Aktuellen Gefühlszustand der Lernenden ausfindig machen
- Lernerfolg vorhersagen

Obwohl Learning Analytics insbesondere auf Lernprozesse fokussieren, liefern die gewonnenen Ergebnisse Vorteile für alle am Lernprozess Beteiligten. Für einen strukturierten Überblick bietet sich eine Aufgliederung der Vorteile nach Zielgruppen sowie Analyseperspektiven an. Tab. 1 zeigt eine Übersicht der vielschichtigen Nutzungsformen von Learning Analytics für summative Berichte, für den laufenden Prozess sowie für Prognosen (Ifenthaler 2015).

Tab. 1 Übersicht zum Nutzen von Learning Analytics (Ifenthaler 2015)

Perspektive Zielgruppe	Summativ	Echtzeit (Formativ)	Prognose
Politische Ebene	<ul style="list-style-type: none"> • Institutionsübergreifende Vergleiche • Entwicklung von Maßstäben • Informationsquelle für Entscheidungsträger • Informationsquelle für Qualitätssicherungsprozesse 	<ul style="list-style-type: none"> • Produktivität erhöhen • Ermöglicht schnelle Reaktion auf kritische Vorfälle • Performanzanalyse 	<ul style="list-style-type: none"> • Einfluss auf organisationale Entscheidungen • Einfluss in Change Management Planung
Institutionelle Ebene	<ul style="list-style-type: none"> • Prozessanalysen • Ressourcenverteilung optimieren • Institutionelle Standards einhalten • Vergleich von Einheiten über Programme und Fachbereiche hinweg 	<ul style="list-style-type: none"> • Prozesse überwachen • Ressourcen evaluieren • Einschreibungen überwachen • Fluktuation analysieren 	<ul style="list-style-type: none"> • Prozesse vorhersagen • Projektoptimierung • Bildungsrate entwickeln • Diskrepanzen identifizieren
Instruktionsdesign	<ul style="list-style-type: none"> • Pädagogische Modelle analysieren • Effekte von Interventionen messen • Verbessern der Curriculaqualität 	<ul style="list-style-type: none"> • Lerndesigns vergleichen • Lernmaterialien evaluieren • Schwierigkeitsgrade anpassen • Von Lernenden benötigte Hilfsmittel anbieten 	<ul style="list-style-type: none"> • Lernpräferenzen identifizieren • Plan für zukünftige Interventionen • Bildungswege anpassen
Lehrkraft	<ul style="list-style-type: none"> • Vergleich von Lernenden, Kohorten und Kursen • Lehrpraktiken analysieren • Lehrqualität verbessern 	<ul style="list-style-type: none"> • Lernentwicklungen überwachen • Sinnvolle Interventionen entwickeln • Interaktion erhöhen • Inhalte anpassen, um den Bedürfnissen der Lernerkohorte entgegen zu kommen 	<ul style="list-style-type: none"> • Gefährdete Lernende identifizieren • Lernentwicklungen vorhersagen • Interventionen planen • Bestehensquote anpassen
Lernende	<ul style="list-style-type: none"> • Lerngewohnheiten verstehen • Lernwege vergleichen • Lernergebnis analysieren • Lernfortschritt im Bezug auf Lernziele verfolgen 	<ul style="list-style-type: none"> • Automatische Interventionen und Lernhilfen erhalten • Prüfungen ablegen und Echtzeit-Feedback erhalten 	<ul style="list-style-type: none"> • Lernwege optimieren • Empfehlungen annehmen • Einsatzbereitschaft erhöhen • Erfolgsquote erhöhen

4 Anwendungsszenarien

4.1 Purdue University: Course Signals

Eines der ersten Beispiele für die Nutzung von Analyseinstrumenten im Bildungsbereich ist das Course Signals System, das an der Purdue University, USA entwickelt wurde. Course Signals bezieht dabei demografische Daten, frühere akademische Leistungen und den Lernaufwand sowie Leistungen innerhalb der Lernplattform in die Leistungsvorhersage der Kursteilnehmer mit ein. Durch die Verwendung eines Ampelsystems (rot: hohes Misserfolgsrisiko; gelb: eventuelles Misserfolgsrisiko; grün: hohe Bestehenswahrscheinlichkeit) werden sowohl Lernende als auch Lehrende frühzeitig auf drohende Risiken hingewiesen. Lehrende können daraufhin mit den Lernenden in Kontakt treten und auf Hilfsangebote hinweisen oder sie anbieten (Pistilli und Arnold 2010). Die empirische Begleitforschung an der Purdue University zeigt, dass mittels dieser einfachen Anwendung signifikant weniger Studierende das Studium abgebrochen haben und bessere akademische Leistungen erzielen (Pistilli und Arnold 2010). Lehrende geben an, dass die Interaktion mit Studierenden erleichtert wird und somit gezieltere Interventionen möglich werden. Die Grenzen von Course Signals bestehen in den zur Verwendung kommenden linearen Algorithmen und der geringen Anzahl von verfügbaren Indikatoren.

4.2 Open Universities Australia: PASS

Open Universities Australia ist eine internationale Online-Universität in Australien, die Kurse und Programme von mehr als 20 australischen Universitäten anbietet. Vor dem Hintergrund einer optimalen Unterstützung der Onlinelernenden wurde das PASS System (Personalised Adaptive Study Success) entwickelt (Ifenthaler und Widanapathirana 2014). PASS verwendet Daten von Lernenden (z. B. individuelle Lernvoraussetzungen) und von digitalen Lernumgebungen (z. B. Logfiles der Lernplattform) und verbindet diese mit zu erreichenden Kompetenzen des Curriculums (z. B. spezifische Lernergebnisse eines Kurses).

Abb. 5 zeigt ein für Lernende konzipiertes Dashboard des PASS Systems. Dabei handelt es sich um ein universelles Plugin, welches in eine Lernplattform integriert wird. Das Dashboard zeigt verschiedene personalisierte Informationen in Echtzeit an, kann aber vom Nutzer flexibel konfiguriert werden. So werden zum Beispiel Lernmaterialien dem aktuellen Lernfortschritt entsprechend empfohlen und Selbsttests zur Überprüfung des Lernfortschritts vorgeschlagen. Visuelle Signale unterstützen die Navigation durch die sich dynamisch ändernden Informationen des Dashboards. Lernende, die einen ähnlichen Lernstand aufweisen, werden als Lernpartner vorgestellt oder es werden Lernende aus fortgeschrittenen Kursen als Lernexperten empfohlen. Umfangreiche Reflektionshinweise, zum Beispiel zu bereits erreichten Lernzielen, können die Lernenden auf Wunsch ein- oder ausblenden. Umfangreiche, grafisch aufbereitete Statistiken geben den Lernenden Einblicke in den individuellen Lernprozess und -fortschritt. Darüber hinaus können Vergleiche zu

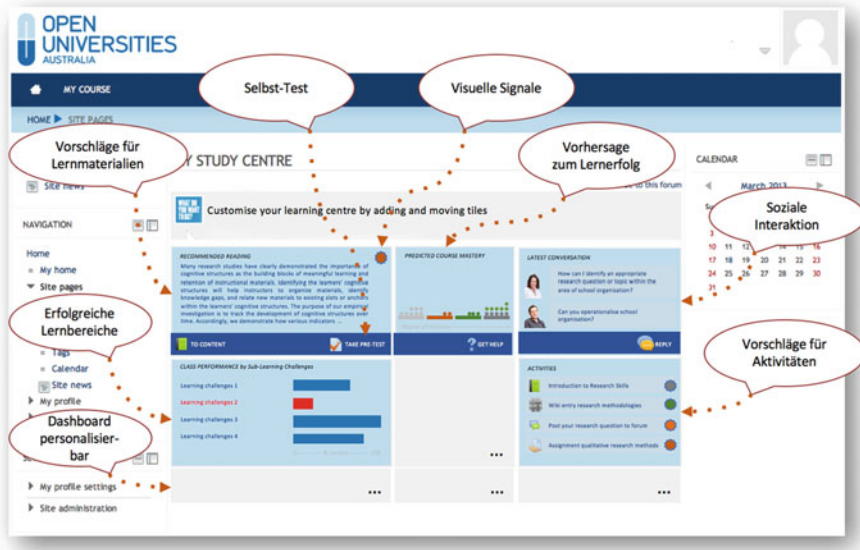


Abb. 5 PASS Dashboard für Lernende

anderen Lernenden herangezogen werden. Über reaktive Datenerhebungen (sogenannte real-time prompts) werden Daten von Lernenden während der Interaktion mit dem PASS System, zum Beispiel zur Motivation oder zur aktuellen Lernstrategie, gesammelt. Das PASS System bietet neben dem Dashboard für Lernende speziell konzipierte Dashboards für Institutionen, für Lehrende und für Kursdesigner an. Die Algorithmen des PASS Systems wurden vor dem Hintergrund umfangreicher empirischer Analysen entwickelt und validiert (Ifenthaler und Widanapathirana 2014).

4.3 RWTH Aachen: eLAT

An der RWTH Aachen wurde 2010/11 die Learning Analytics Anwendung eLAT (exploratory Learning Analytics Toolkit) eingeführt. Ziel der Anwendung ist es, mittels Analyse von Daten wie Teilnahme an Übungen, Erstellen von Forenbeiträgen und Lesen und Herunterladen von Lerninhalten, Lehr-Lern-Prozesse zu evaluieren und mögliche Verhaltensveränderungen der Lehrenden zu erfassen und mögliche Verbesserungen der Lehre einzuleiten (Dyckhoff et al. 2012). Da die Anwendung im Bereich Informatik entwickelt wurde, liegt das Forschungsinteresse verstärkt auf Usability-Aspekten, der Integrierbarkeit der Anwendung in verschiedene Lernplattformen sowie der Visualisierung der analysierten Daten. Darüber hinaus wird vor allem auf den Nutzen für Lehrkräfte eingegangen, die Mithilfe von eLAT ihre Lehre reflektieren und verbessern können, indem sie Hypothesen mittels Indikatoren und Filteroptionen abfragen. Dennoch erhalten auch Lernende individuelles

Feedback vom System. Die eLAT-Anwendung liefert hinsichtlich Usability-Gesichtspunkten, Datenschutzumsetzung, Visualisierungsmöglichkeiten, Indikatorbildung und der Integrierbarkeit in verschiedene Lernplattformen überzeugende Ansätze zur Entwicklung einer Learning Analytics-Anwendung (Ifenthaler und Schumacher 2016a).

4.4 Universität Mannheim: LeAP

Ziel des an der Universität Mannheim umgesetzten LeAP (www.leap.uni-mannheim.de; Learning Analytics Profiles)-Projekts ist die Entwicklung, Implementation und empirische Erforschung eines Plug-In als Learning Analytics-Anwendung, welches mittels gezielter pädagogischer Interventionen die Studieneingangsphase und den weiteren Studienverlauf personalisiert und adaptiv optimiert. Die bereits vorhandenen technischen Systeme (HISinOne [Online-Service Studium und Lehre] und ILIAS [Learning Management System]) an der Universität Mannheim bilden die Grundlage für das Projektvorhaben. Abb. 6 zeigt die zu implementierende Learning Analytics-Architektur in Verbindung mit der bereits vorhandenen technischen Infrastruktur. Das Lernenden-Profil beinhaltet Informationen der Lernenden (z. B. Lernhistorie, Vorwissen, Interesse). Das Lern-Profil integriert Daten aus dem Lernmanagementsystem (z. B. Log-Files, Testergebnisse). Das Curriculum-Profil bildet die formalen Lehr-Lernprozesse einzelner Kurse bzw. Module ab (z. B. erwartete Lernergebnisse, erwartete Sequenzierung von Lernpfaden).

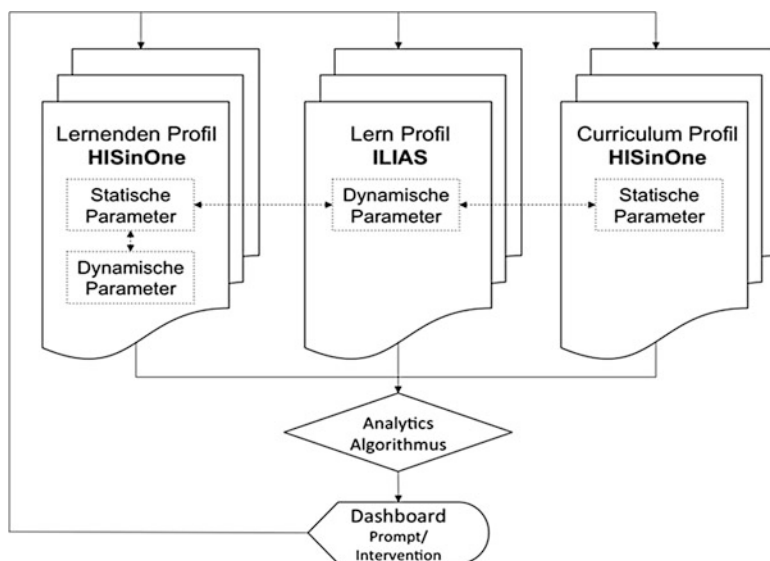


Abb. 6 Learning Analytics-Architektur und vorhandene Infrastruktur

4.5 Open University der Niederlande

An der Open University der Niederlande wurde ein Learning Analytics Dashboard entwickelt, dass vor allem auf die Unterstützung von Gruppenprozessen in online-Lernumgebungen abzielt (Scheffel et al. 2016, 2017a). Das sogenannte LASER Dashboard bietet mehrere Arten des Feedbacks in Form einer Radargrafik und verschiedener Balkendiagramme an (siehe Abb. 7). LASER versucht Studenten ihren eigenen Lernprozess und ihren Beitrag an der Gruppenarbeit bewusster zu machen. Die Gruppenperformance ist Bestandteil der monatlichen Onlineseminare der Studierenden und ein wichtiges Hilfsmittel für das weitere Planen der Gruppenarbeit und die weitere Aufgabenverteilung. Die Studierenden sind sehr zufrieden mit dem LASER Dashboard, weil es nach ihren Angaben interessant ist und hilft, mögliche Konflikte frühzeitig zu erkennen sowie zu diskutieren.

Neben der Unterstützung von Gruppenprozessen hat das LASER Dashboard noch eine weitere Besonderheit im Vergleich zu anderen Learning Analytics Dashboards: die Integration eines wechselseitigen Datenschutz-Modells (Reciprocal Privacy Model – RPM) nach den Gedanken der DELICATE-Checklist (Drachsler und Greller 2016). Das RPM ermöglicht es den Studierenden selbst zu entscheiden, ob sie ihre Aktivitätsdaten mit ihren Gruppenmitgliedern teilen wollen oder nicht. Dabei liegt ein einfacher, aber sehr effektiver Mechanismus zugrunde, der es Studierenden nur ermöglicht die Daten der anderen Studierenden zu sehen, wenn Sie ihre eigenen Daten ebenfalls freigeben. Wenn ein Studierender mit dem Austausch seiner Daten nicht einverstanden ist, kann er diese sperren und sieht nur seinen eigenen Beitrag im Vergleich zum aggregierten Gruppenbeitrag angezeigt (große blaue Fläche auf Abb. 7). Teilt ein Studierender seine Daten, dann bekommt er auch die Daten und Performance der anderen Studierenden angezeigt.

5 Fazit

Learning Analytics entwickeln sich rasant. Bildungsinstitutionen müssen jedoch Kapazitäten entwickeln, um dieser Entwicklung folgen zu können (Drachsler et al. 2014; Ifenthaler 2017). Dazu gehört beispielsweise, Lehrende im Umgang und in der Bewertung von Lerninformationssystemen und Dashboards fortzubilden und eine Lernkultur zu entwickeln, wie Unterrichtsprozesse auf Grundlage der verfügbaren Learning Analytics-Daten gestaltet werden können (Gibson und Ifenthaler 2017; Jivet et al. 2017). Auch die transparente Einbeziehung von Lernenden muss mitbedacht werden, damit Feedback sinnvoll genutzt werden kann. Nicht zuletzt müssen auch Entscheider auf allen Ebenen des Bildungssystems in der Lage sein, die Informationen aus Learning Analytics sinnvoll zu verwenden. Richtig eingesetzt können Daten zur Weiterentwicklung des Bildungssystems beitragen und einen Mehrwert für Lernende, Lehrende und institutionelle Entscheidungsträger gleichermaßen darstellen (Bellin-Mularski und Ifenthaler 2014). Zur Bewertung und Evaluation von Learning Analytics an sich ist vor allem auf die Arbeiten von

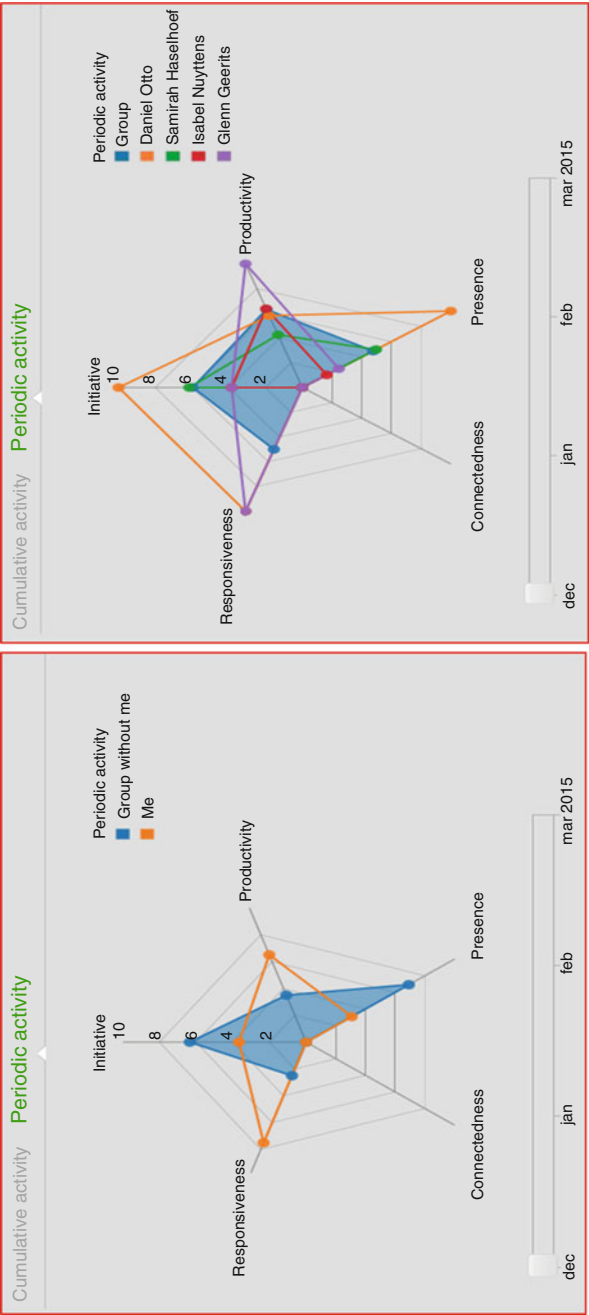


Abb. 7 LASER Dashboard mit dem wechselseitigen Datenschutz-Model (Reciprocal Privacy Model – RPM) (Scheffel et al. 2017a). In der linken Grafik ist das Datenteilen zwischen Studenten deaktiviert, während in der rechten Grafik das gegenseitige Teilen der Daten aktiviert ist

Maren Scheffel (Scheffel et al. 2017a, b; Scheffel 2017) zu verweisen, die eine Evaluationsmethode für Learning Analytics entwickelt hat. Das sogenannte ‚Evaluation Framework for Learning Analytics (EFLA)‘ orientiert sich hierbei an der SUS scale aus der Usability Forschung und zielt damit darauf ab, eine vergleichbare und schnelle Methode für die Evaluation von Learning Analytics im Feld zu ermöglichen (Scheffel 2017).

Learning Analytics sind im deutschsprachigen Raum ein noch vergleichsweise wenig beachtetes Thema, was sich beispielsweise an der Zahl der aktuellen Veröffentlichungen und implementierten Learning Analytics-Anwendungen zeigt (Ifenthaler und Schumacher 2016a). Im englischsprachigen Ausland hingegen werden Learning Analytics stärker diskutiert und finden bereits praktische Anwendung durch die Implementierung von Learning Analytics-Anwendungen an einer Vielzahl von Universitäten (vgl. Johnson et al. 2013).

In der internationalen Forschung werden Learning Analytics ein zunehmend umfassenderes Forschungsthema, das nicht nur Lern-Management-Systeme und mobile Geräte und LernApps erfasst (Tabuenca et al. 2015), sondern auch zunehmend Datenquellen aus sogenannten Wearables und anderen Video- und Audio-Sensoren berücksichtigt (Pijera-díaz et al. 2016). Diese sogenannten multimodalen Daten aus einer Vielzahl von Sensoren stellen die Learning Analytics-Forschung vor neue Herausforderungen, geben der Lehr-Lernforschung allerdings die Möglichkeit ganz neue wissenschaftliche Erkenntnisse zu gewinnen (Di Mitri et al. 2017).

Eine lerntheoretisch fundierte und validierte Auswahl der zu analysierenden Daten sowie die pädagogische Entscheidung, welche Informationen den Stakeholdern zugänglich gemacht werden sollen und in welcher Form, ist jedoch unumgänglich (Ifenthaler und Widanapathirana 2014). Auch hinsichtlich der empirisch validierten Auswahl von Indikatoren für die Analysealgorithmen besteht Nachholbedarf, da Lernen häufig mit Variablen wie Login-Häufigkeiten, Anzahl der Gruppendiskussionsbeiträge oder der termingerechten Bearbeitung gleichgesetzt wird (Scheffel et al. 2014) – dies ist aus Sicht der Lehr-Lern-Forschung unzureichend. Denn nicht nur die Menge der Beiträge oder die Nutzungsdauer, sondern vor allem der Inhalt ist ein Indikator für Lernen (Ifenthaler und Schumacher 2016a; Macfadyen und Dawson 2012). Aktuelle Lösungsansätze sind Netzwerkanalysen, wodurch die Dynamik von Gruppenstrukturen erfasst werden kann (vgl. Buckingham Shum und Ferguson 2012) oder automatisierte semantische Analysen, welche textbasierte Inhalte vergleichen (Ifenthaler 2014).

Holistische Learning Analytics-Anwendungen, die theoretisch fundierte Datenanalysen mit pädagogisch relevanten Lernindikatoren und aufbereitete Interventionen ermöglichen, sind Ziel der aktuellen Forschung (vgl. Greller und Drachsler 2012; Ifenthaler 2017). Dabei ist zu erwarten, dass neben datenschutzrechtlichen Standards in der Verwendung von Daten auch weitere Standards zum Austausch von Daten aus dem Bildungskontext entwickelt werden. Eine aus pädagogischer Sicht ungelöste Frage bleibt jedoch: Unterstützen Learning Analytics den Lehr-Lern-Prozess nachhaltig und wenn ja, in welchem Umfang?

Literatur

- Bellin-Mularski, N., & Ifenthaler, D. (2014). Learning analytics: Datenanalyse zur Unterstützung von Lehren und Lernen in der Schule. *SchulVerwaltung NRW*, 25(11), 300–303.
- Berg, A., Scheffel, M., Ternier, S., Drachsler, H., & Specht, M. (2016). Dutch cooking with xAPI recipes – The good, the bad, and the consistent. 16th IEEE international conference on advancing learning technologies (ICALT 2016). Austin.
- Berland, M., Baker, R. S. J. d., & Bilkstein, P. (2014). Educational data mining and learning analytics: Applications to constructionist research. *Technology, Knowledge and Learning*, 19(1–2), 205–220. <https://doi.org/10.1007/s10758-014-9223-7>.
- Buckingham Shum, S., & Ferguson, R. (2012). Social learning analytics. *Educational Technology & Society*, 15(3), 3–26.
- d'Aquin, M., Dietze, S., Herder, E., Drachsler, H., & Taibi, D. (2014). Using linked data in learning analytics. eLearning papers, 36. <http://www.openeducationeuropa.eu/en/download/file/fid/33993>. Zugegriffen am 12.10.2017.
- Di Mitri, D., Scheffel, M., Drachsler, H., Börner, D., Ternier, S., & Specht, M. (2017). Learning pulse: A machine learning approach for predicting performance in self-regulated learning using multimodal data. 7th learning analytics and knowledge conference 2017. Vancouver.
- Drachsler, H. & Greller, W. (2016). Privacy and analytics – It's a DELICATE issue. A checklist to establish trusted learning analytics. 6th learning analytics and knowledge conference 2016. (S. 89–98), 25–29 April 2016. Edinburgh/New York: ACM.
- Drachsler, H., & Kalz, M. (2016). The MOOC and learning analytics innovation cycle (MOLAC): A reflective summary of ongoing research and its challenges. *Journal of Computer Assisted Learning*, 32(3), 281–290. <https://doi.org/10.1111/jcal.12135>.
- Drachsler, H., Stoyanov, S., & Specht, M. (2014). The impact of learning analytics on the Dutch education system. Presentation given at the 4th international conference on learning analytics and knowledge. Indianapolis.
- Drachsler, H., Verbert, K., Santos, O. C., & Manouselis, N. (2015). Panorama of recommender systems to support learning. In F. Ricci, L. Rokach & B. Shapira (Hrsg.), *2nd handbook on recommender systems* (S. 421–451). USA: Springer. https://doi.org/10.1007/978-1-4899-7637-6_12.
- Dyckhoff, A. L., Zielke, D., Bültmann, M., Chatti, M. A., & Schroeder, U. (2012). Design and implementation of a learning analytics toolkit for teachers. *Educational Technology & Society*, 15(3), 58–76.
- Endsley, M. R. (1995). Toward a theory of situation awareness in dynamic systems. *Human Factors*, 37, 32–64.
- Fazeli, S., Loni, B., Drachsler, H., & Sloep, P. (2014). Which recommender system can best fit social learning platforms? Presentation given at the 9th European conference on technology enhanced learning (EC-TEL2014). Graz.
- Gibson, D. C., & Ifenthaler, D. (2017). Preparing the next generation of education researchers for big data in higher education. In B. Kei Daniel (Hrsg.), *Big data and learning analytics: Current theory and practice in higher education* (S. 29–42). New York: Springer.
- Greller, W., & Drachsler, H. (2012). Translating learning into numbers: A generic framework for learning analytics *Educational Technology & Society*, 15(3), 42–57.
- Ifenthaler, D. (2012). Determining the effectiveness of prompts for self-regulated learning in problem-solving scenarios. *Journal of Educational Technology & Society*, 15(1), 38–52.
- Ifenthaler, D. (2014). AKOVIA: Automated knowledge visualization and assessment. *Technology, Knowledge and Learning*, 19(1–2), 241–248. <https://doi.org/10.1007/s10758-014-9224-6>.
- Ifenthaler, D. (2015). Learning analytics. In J. M. Spector (Hrsg.), *The SAGE encyclopedia of educational technology* (Bd. 2, S. 447–451). Thousand Oaks: Sage.
- Ifenthaler, D. (2017). Are higher education institutions prepared for learning analytics? *TechTrends*, 61(4), 366–371. <https://doi.org/10.1007/s11528-016-0154-0>.

- Ifenthaler, D., & Schumacher, C. (2016a). Learning Analytics im Hochschulkontext. *WiSt – Wirtschaftswissenschaftliches Studium*, 4, 172–177.
- Ifenthaler, D., & Schumacher, C. (2016b). Student perceptions of privacy principles for learning analytics. *Educational Technology Research and Development*, 64(5), 923–938. <https://doi.org/10.1007/s11423-016-9477-y>.
- Ifenthaler, D., & Tracey, M. W. (2016). Exploring the relationship of ethics and privacy in learning analytics and design: Implications for the field of educational technology. *Educational Technology Research and Development*, 64(5), 877–880. <https://doi.org/10.1007/s11423-016-9480-3>.
- Ifenthaler, D., & Widanapathirana, C. (2014). Development and validation of a learning analytics framework: Two case studies using support vector machines. *Technology, Knowledge and Learning*, 19(1–2), 221–240. <https://doi.org/10.1007/s10758-014-9226-4>.
- Ifenthaler, D., Bellin-Mularski, N., & Mah, D.-K. (2015). Internet: Its impact and its potential for learning and instruction. In J. M. Spector (Hrsg.), *The SAGE encyclopedia of educational technology* (Bd. 1, S. 416–422). Thousand Oaks: Sage.
- Jivet, I., Scheffel, M., Drachsler, H., & Specht, M. (2017). Awareness is not enough. Pitfalls of learning analytics dashboards in the educational practise. 12th European conference on technology-enhanced learning. Tallinn, 12–15 Sept. 2017.
- Johnson, L., Adams Becker, S., Cummins, M., Freeman, A., Ifenthaler, D., & Vardaxis, N. (2013). *Technology outlook for Australian tertiary education 2013–2018: An NMC horizon project regional analysis*. Austin: The New Media Consortium.
- Long, P. D., & Siemens, G. (2011). Penetrating the fog: Analytics in learning and education. *Educause Review*, 46(5), 31–40.
- Macfadyen, L., & Dawson, S. (2012). Numbers are not enough. Why e-Learning analytics failed to inform an institutional strategic plan. *Educational Technology & Society*, 15(3), 149–163.
- New York Times. (2014). InBloom Student Data Repository to Close, 21 April 2014. http://bits.blogs.nytimes.com/2014/04/21/inbloom-student-data-repository-to-close/?_r=0. Zugegriffen am 12.10.2017.
- Pijera-díaz, H. J., Drachsler, H., Järvelä, S., & Kirschner, P. A. (2016). Investigating collaborative learning success with physiological coupling indices based on electrodermal activity. 6th learning analytics and knowledge conference 2016. 25–29 April 2016. Edinburgh.
- Pistilli, M. D., & Arnold, K. E. (2010). Purdue signals: Mining real-time academic data to enhance student success. *About campus: Enriching the student learning experience*, 15(3), 22–24.
- Scheffel, M. (2017). The evaluation framework for learning analytics. Doctoral thesis. Heerlen: Open Universiteit (Welten Institute, Research centre for learning, Teaching and technology). <http://dspace.ou.nl/handle/1820/8259>.
- Scheffel, M., Drachsler, H., Stoyanov, S., & Specht, M. (2014). Quality indicators for learning analytics. *Educational Technology & Society*, 17(4), 117–132.
- Scheffel, M., Drachsler, H., de Kraker, J., Kreijns, K., Sloomaker, A., & Specht, M. (2016). Widget, widget on the wall, am I performing well at all? *IEEE Transactions on Learning Technologies*, 10(1), 42–52. <https://doi.org/10.1109/TLT.2016.2622268>.
- Scheffel, M., Drachsler, H., Kreijns, K., de Kraker, J., & Specht, M. (2017a). Widget, widget as you lead, I am performing well indeed! – Using results from a formative offline study to inform an empirical online study about a learning analytics widget in a collaborative learning environment. Proceedings of the (LAK'17). Vancouver: ACM.
- Scheffel, M., Drachsler, H., Toisoul, C., Ternier, S., & Specht, M. (2017b). The Proof of the pudding: Examining validity and reliability of the evaluation framework for learning analytics. In E. Lavoué, H. Drachsler, K. Verbert, J. Broisin & M. Pérez-Sanagustín (Hrsg.), *Data driven approaches in digital education*. Proceedings of the 12th European conference on technology enhanced learning (EC-TEL 2017), LNCS (Bd. 10474, S. 194–208). Berlin/Heidelberg: Springer.
- Siemens, G., Dawson, S., & Lynch, G. (2014). *Improving the quality and productivity of the higher education sector – Policy and strategy for systems-level deployment of learning analytics*.

- Canberra, Australia: Office of Learning and Teaching, Australian Government. http://solarresearch.org/Policy_Strategy_Analytics.pdf.
- Tabuenca, B., Kalz, M., Drachsler, H., & Specht, M. (2015). Time will tell: The role of mobile learning analytics in self-regulated learning. *Computers & Education*, 89, 53–74.
- Verbert, K., Manouselis, N., Drachsler, H., & Duval, E. (2012). Dataset-driven research to support learning and knowledge analytics. *Educational Technology & Society*, 15(3), 133–148.
- Zimmerman, B. J. (1995). Self-regulation involves more than metacognition: A social cognitive perspective. *Educational Psychologist*, 30(4), 217–221.